

基礎氣候變遷氣候資料分析與資料視覺化

HW6 & HW7

Basics of Machine Learning

系級：森林環境暨資源學系碩一

學號：R11625008

姓名：黃士祥

2023/6/4

Task 1: Will performance on a true, uncorrelated test set be better or worse than performance on the biased dataset?

由於海溫資料時常具有記憶效應，導致較鄰近的資料可能會有自我相關之疑慮。本題為了證實此效應，使用 1960~1975 年的資料作為訓練集，並分別以 1976~1981 (圖 1.左) 及 2000~2005 (圖 1.右) 作為驗證集。分析結果發現使用鄰近訓練集的驗證集所得之相關係數為 0.72，而使用時間較遠之驗證集所得之相關係數為 0.85。此結果顯示記憶效應在海溫模型的訓練及預測上確實有所影響。




圖 1. 海溫資料相關性分析圖。註：左圖為使用 1960~1975 年的資料作為訓練集，1976~1981 作為驗證集。右圖為使用 1960~1975 年的資料作為訓練集，2000~2005 作為驗證集。

Task 2: For longer lead times, would model performance improve or worsen?

為瞭解模型領先預測期 (lead time) 的表現狀況，故分析 lead time 為 1 個月 (圖 2)、2 個月 (圖 3) 及 3 個月 (圖 4) 之模型相關係數。由計算結果發現相關係數分別為 0.85、0.75 及 0.69，顯示領先預測期越長，預測出之結果越不準。




圖 2. Lead time=1 之模型折線圖。




圖 3. Lead time=2 之模型折線圖。




圖 4. Lead time=3 之模型折線圖。

Task 3: What data sources improve the ML algorithm? What data sources do not improve the ML algorithm?

為了想得知較久遠的訓練資料對鄰近資料及較遠資料之預測結果為何，故以 1900-01-01~1920-12-31 作為訓練集，並分別以鄰近資料：1940-01-01~1945-12-31 及較遠資料：2005-01-01~2010-12-31 來進行分析。分析結果發現較鄰近資料所計算出之相關係數為 0.87；而以較遠資料所計算出之相關係數為 0.83。此現象顯示較久遠之資料可能因測量工具誤差抑或是當時的狀況和現今有所差異，導致在預測近期狀況時，模型預測的結果與實際值有所落差。




圖 5. 左圖為鄰近資料之預測折線圖；右圖為使用較遠資料之預測折線圖。

Task 4: Use linear regression to conduct ENSO prediction

為瞭解模型領先預測期 (lead time) 的表現狀況，故分析 lead time 為 1 個月 (圖 6)、3 個月 (圖 7) 及 5 個月 (圖 8) 之模型相關係數及方均根誤差。由計算結果發現相關係數分別為 0.93、0.82 及 0.65，顯示領先預測期越長，預測出之結果相關性越低。RMSE 的部分，三組不同之 lead time 分別為 0.14、0.35 及 0.52，此結果可對應到相關性的分析，即領先預測期越大，則相關性越低、誤差越大。




圖 6. Lead time=1 之線性回歸模型折線圖。




圖 7. Lead time=3 之線性回歸模型折線圖。

Linear Regression Predicted and True Nino3.4 Indices on Test Set at 5 Month Lead Time. Corr: 0.65. RMSE: 0.52




圖 8. Lead time=5 之線性回歸模型折線圖。

Task 6: Use random forest to classify ENSO prediction

為了要評估隨機森林模型的表現結果，故計算 F1 score 及 accuracy。F1 score 為一種結合模型精確度 (precision) 和召回率 (recall) 的評估指標，而 accuracy 則為評估模型在分類問題中正確預測的比例。本作業所計算出之 F1 score 為 0.89，accuracy 為 0.93，模型表現尚佳。

```
# calculate the confusion matrix
from sklearn.metrics import f1_score, accuracy_score, mean_squared_error, r2_score
print(f"F1 Score: {round(f1_score(y_class_test, y_rfpred, average='macro'), 2)}")
print(f"Accuracy: {round(accuracy_score(y_class_test, y_rfpred), 2)}")

F1 Score: 0.89
Accuracy: 0.93
```

圖 9. ENSO 隨機森林模型表現程式碼。